

Fecha Inicio	22/09/2026
Duración Estimada	14-15 semanas.
Título	BIODATAPHARMA: Sistema inteligente que automatiza la recolección, ordenación y análisis de datos de medicamentos en base a enfermedades.
Supervisor Proyecto	Guillermo Gallego Reina: ggallego@icai.comillas.edu Adriana Carla Moreno Alonso: acmolero@icai.comillas.edu Emilio García Orellana: egorellana@comillas.edu
Área/s temáticas principales	ETL, Data Engineering, Machine Learning, Inteligencia Artificial.
Breve descripción del proyecto/Esquema	Este proyecto nace de la necesidad de optimizar la estrategia de gestión de datos y optimización de recursos sanitarios de la compañía, ya que la actual no cumple con los KPIs mínimos establecidos. La compañía basa todos sus trabajos sobre el sector farmacéutico y de salud en España, enfocados en el catálogo y las fichas técnicas del CIMA y del Ministerio de Sanidad. Los principales requisitos funcionales sobre los que se sustenta el proyecto son: - Se requiere tener como fuentes de origen la API {REST} CIMA, Web Scraping CIMA y los datos del Ministerio de Sanidad en base a la enfermedad propuesta a cada grupo. - Se dispondrá de una base de datos MySQL para identificar las compañías farmacéuticas, los códigos nacionales (CN), CIK u otra información relevante sobre ellas (Tablas CIMA, Fichas y SNS). - Se requiere hacer uso de ETLs para tener la información de los medicamentos/compañías para posteriormente ser usados como <i>inputs</i> para el modelo. - Se requiere realizar un modelo de <i>machine learning</i> (clasificador para detección automática de criticidad/tipo) el cual en mayor o menor medida pueda ser explicado a cada uno de los departamentos. - Se requiere documentar de manera detallada y justificada por qué se ha hecho uso de las tecnologías. - Enfermedades: cáncer, diabetes, hipertensión, asma, epilepsia, migraña, artritis reumatoide, psoriasis, esquizofrenia.

	vii. Esquema: <pre> graph LR subgraph Extracción FE[Fuentes Externas] end subgraph Limpieza_y_Calidad_de_los_Datos EDA[Entorno EDA & Machine Learning] end subgraph Almacenamiento_Consolidado TC[Tablas CIMA] TF[Tablas Fichas] TS[Tablas SNS] end subgraph Visualización_y_Storytelling_con_Datos PBD[Power BI Dashboard] TA[Tableau Analytics] SL[Streamlit] end FE --> EDA EDA --> TC EDA --> TF EDA --> TS TC --> PBD TC --> TA TC --> SL TF --> PBD TF --> TA TF --> SL TS --> PBD TS --> TA TS --> SL </pre> Fuentes Externas API (REST) CIMA Consulta por tipología de enfermedad (cáncer, infarto, ictus, EPOC, etc.) -> Obtener Código Nacional (CN). WEB SCRAPING CIMA Extracción automática de características técnicas de Fichas Técnicas (PDF/HTML). CSV Ministerio Sanidad Descarga de variables económicas (PVP-IVA, etc.) de prestación farmacéutica. Entorno EDA & Machine Learning Análisis Exploratorio (EDA) con Jupyter automática de criticidad / tipo. Machine Learning (Clasificador): Detección automitad / tipo. Almacenamiento Consolidado Tablas CIMA Tablas Fichas Tablas SNS Visualización y Storytelling con Datos Power BI Dashboard Tableau Analytics Streamlit Streamlit Web App AUTOMATIZACIÓN - Flujo de Ingesta
Recursos requeridos	Hacer uso de Python y herramientas necesarias para la extracción, carga y análisis de los datos pedidos.
Metodología	El Proyecto estará basado en Scrum con el objetivo de proponer un modo de trabajo ágil. • Sprint Planning. • Daily Scrum. • Sprint Review. • Sprint Retrospective. Los equipos estarán compuestos por un máximo de 4 personas y mínimo 3.
Entrega Final/ Objetivo	Se realizará una presentación con el objetivo de medir el desarrollo de la propuesta.

ACRONIMOS

***sectores:** Biotecnología Farmacéutica (BIO), Bioinformática y Biología Computacional (BIOINF), Genómica y Medicina de Precisión (GEN)

